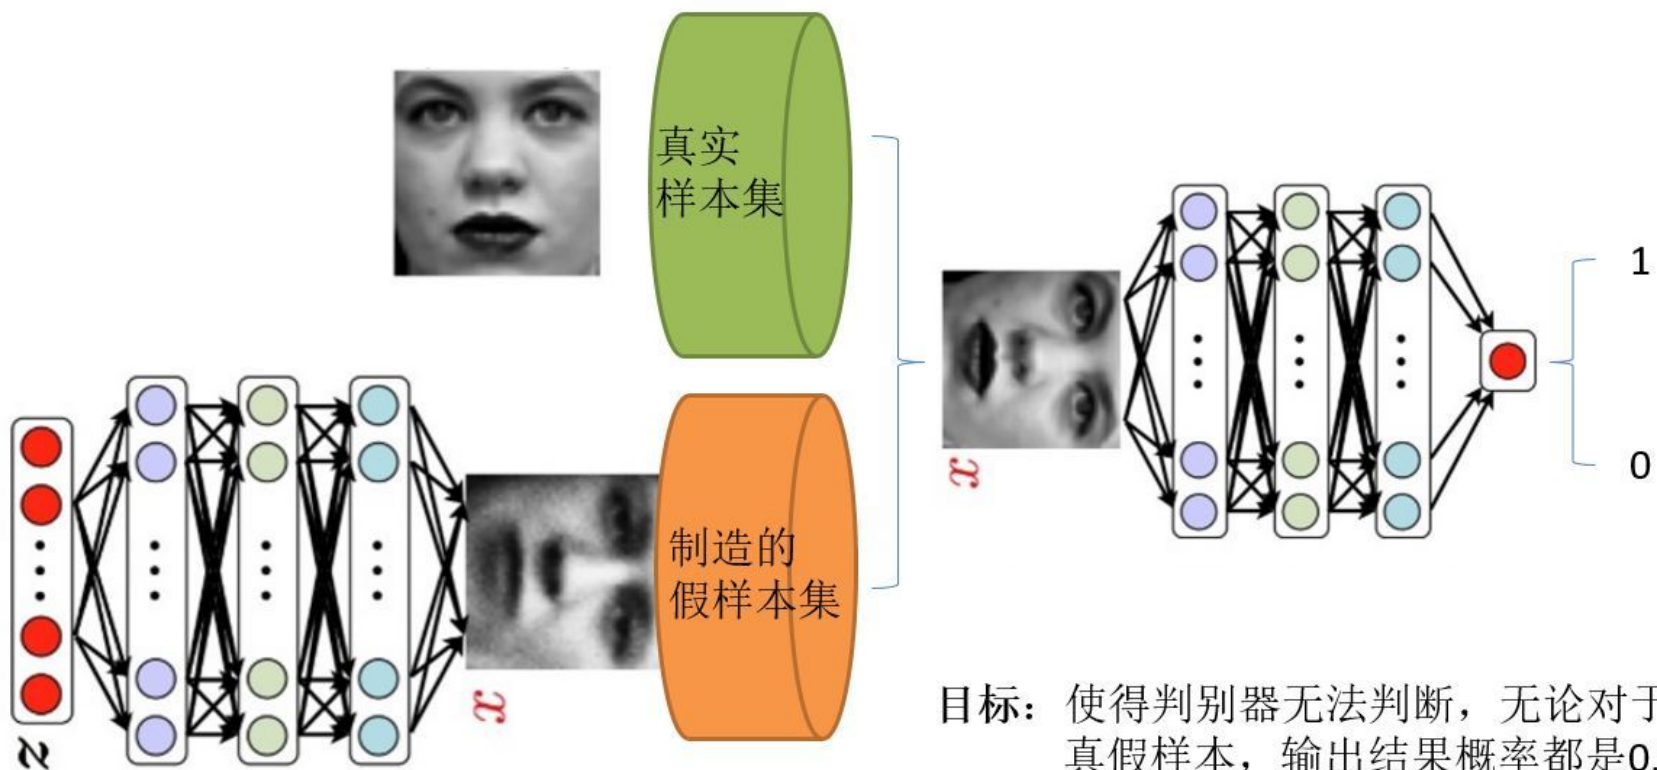


Generative Adversarial Nets



目标：使得判别器无法判断，无论对于真假样本，输出结果概率都是0.5

<http://blog.csdn.net/on2way>

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))].$$


Proposition 1. *For G fixed, the optimal discriminator D is*

$$D_G^*(\mathbf{x}) = \frac{p_{\text{data}}(\mathbf{x})}{p_{\text{data}}(\mathbf{x}) + p_g(\mathbf{x})} \quad (2)$$


Proof. The training criterion for the discriminator D , given any generator G , is to maximize the quantity $V(G, D)$

$$\begin{aligned} V(G, D) &= \int_{\mathbf{x}} p_{\text{data}}(\mathbf{x}) \log(D(\mathbf{x})) dx + \int_{\mathbf{z}} p_{\mathbf{z}}(\mathbf{z}) \log(1 - D(g(\mathbf{z}))) dz \\ &= \int_{\mathbf{x}} p_{\text{data}}(\mathbf{x}) \log(D(\mathbf{x})) + p_g(\mathbf{x}) \log(1 - D(\mathbf{x})) dx \end{aligned} \quad (3)$$


For any $(a, b) \in \mathbb{R}^2 \setminus \{0, 0\}$, the function $y \rightarrow a \log(y) + b \log(1 - y)$ achieves its maximum in $[0, 1]$ at $\frac{a}{a+b}$. The discriminator does not need to be defined outside of $\text{Supp}(p_{\text{data}}) \cup \text{Supp}(p_g)$, concluding the proof. \square



(a)




(b)

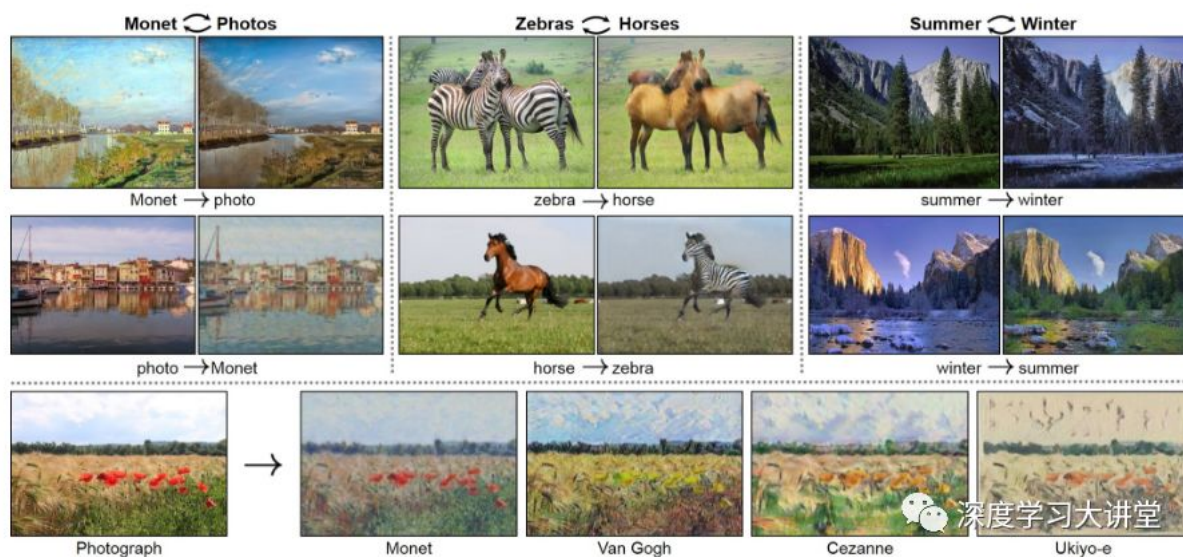



(c)

...



(d)



GAN 的优势

与其他生成式模型相比较，生成式对抗网络有以下四个优势：

根据实际的结果，看上去可以比其它模型产生了**更好的样本（图像更锐利、清晰）**。

生成对抗式网络框架能**训练任何一种生成器网络**。大部分其他的框架需要该生成器网络有一些特定的函数形式，比如输出层是高斯的。重要的是所有其他的框架需要生成器网络遍布非零质量（non-zero mass）。生成对抗式网络能学习可以仅在与数据接近的细流形（thin manifold）上生成点。

不需要设计遵循任何种类的因式分解的模型，任何生成器网络 and 任何鉴别器都会有用。

无需利用马尔科夫链反复采样，无需在学习过程中进行推断（Inference），**回避了近似计算棘手的概率的难题**。

GAN 目前存在的主要问题：

解决不收敛（ non-convergence ）的问题。

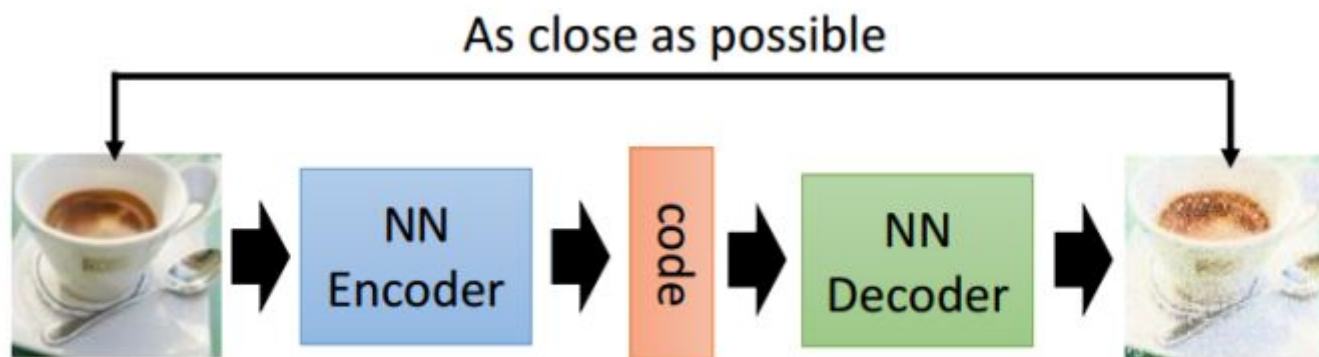
当博弈双方都由神经网络表示时，在没有实际达到均衡的情况下，让它们永远保持对自己策略的调整是可能的。

难以训练：崩溃问题（ collapse problem ）


GAN 模型被定义为极小极大问题，没有损失函数，在训练过程中很难区分是否正在取得进展。 GAN 的学习过程可能发生崩溃问题（ collapse problem ），生成器开始退化，总是生成同样的样本点，无法继续学习。当生成模型崩溃时，判别模型也会对相似的样本点指向相似的方向，训练无法继续。



无需预先建模，模型过于自由不可控

与其他生成式模型相比， GAN 这种竞争的方式不再要求一个假设的数据分布，即不需要 formulate $p(x)$ ，而是使用一种分布直接进行采样 sampling ，从而真正达到理论上可以完全逼近真实数据，这也是 GAN 最大的优势。然而，这种不需要预先建模的方法缺点是太过自由了，对于较大的图片，较多的 pixel 的情形，基于简单 GAN 的方式就不太可控了。




对编码器添加约束，就是强迫它产生服从单位高斯分布的潜在变量





$$l_i(\theta, \phi) = -E_{z \sim q_\theta(z|x_i)}[\log p_\phi(x_i|z)] + KL(q_\theta(z|x_i)||p(z))$$

$$D(p||q) = \sum_{i=1}^n p(x) \log \frac{p(x)}{q(x)}$$



VAE 优势：可以通过编码解码的步骤，直接比较重建图片和原始图片的差异。

VAE 劣势：没有使用对抗网络，所以会更趋向于产生模糊的图片。